

A4 - Daten Importieren

Jan-Philipp Kolb

15 Oktober 2018


Datenimport



Daten mit RStudio importieren

RStudio Funktionalität um Daten zu importieren

- Environment - Import Dataset - Filetyp auswählen



Wo findet man die Daten?

Browse Button in RStudio

Import Excel Data

File/Url:

Data Preview:

Code Vorschau in Rstudio

Code Preview:

```
library(readxl)
ee_recode_questionnaire_coded <- read_excel("data/ee_recode_questionnaire_coded.xls")
View(ee_recode_questionnaire_coded)
```

Import Cancel

csv Daten importieren

- `read.csv` ist ein Befehl, der im Basispaket verfügbar ist.
- Excel-Daten können als `.csv` in Excel gespeichert werden.
- Dann kann `read.csv()` zum Einlesen der Daten verwendet werden.
- Für Deutsche Daten benötigt man eventuell `read.csv2()` wegen der Komma-Trennung.

```
dat <- read.csv("../data/ZA5666_v1-0-0.csv")
```

Wenn es Deutsche Daten sind:

```
datd <- read.csv2("../data/ZA5666_v1-0-0.csv")
```

Das Ergebnis - ein data.frame.

- das folgende data.frame ist ein kleiner Auszug aus den Daten des GESIS-Panels:

```
datd
```

##	z000001z	z000002z	z000003z	z000005z
## 1	198431880	ZA5666	1-0-0 2017-06-20	10.4232/1.12749
## 2	436122330	ZA5666	1-0-0 2017-06-20	10.4232/1.12749
## 3	856844220	ZA5666	1-0-0 2017-06-20	10.4232/1.12749
## 4	117346660	ZA5666	1-0-0 2017-06-20	10.4232/1.12749
## 5	943433330	ZA5666	1-0-0 2017-06-20	10.4232/1.12749
## 6	265582550	ZA5666	1-0-0 2017-06-20	10.4232/1.12749
## 7	275587110	ZA5666	1-0-0 2017-06-20	10.4232/1.12749
## 8	677771880	ZA5666	1-0-0 2017-06-20	10.4232/1.12749
## 9	463671220	ZA5666	1-0-0 2017-06-20	10.4232/1.12749
## 10	478839330	ZA5666	1-0-0 2017-06-20	10.4232/1.12749

Excel-Datensatz importieren - mit `xlsx`.

Paket `xlsx`

- Titel: Read, Write, Format Excel 2007 and Excel 97/2000/XP/2003 Files
- Autoren: Adrian A. Dragulescu, Cole Arendt

```
install.packages("xlsx")
```

```
library("xlsx")  
ab_xlsx <- read.xlsx("../data/ab.xlsx",1)
```

- Das Paket `xlsx` benötigt Java - wenn das nicht verfügbar ist, verwenden Sie den Befehl `read_excel` aus dem Paket `readxl`.

Das Paket readxl

```
install.packages("readxl")
```

- **readxl hat keine externen Abhängigkeiten**
- readxl unterstützt sowohl das alte .xls Format als auch das moderne xml-basierte .xlsx Format.

```
library(readxl)  
ab <- read_excel("../data/ab.xlsx")  
head(ab)
```

```
## # A tibble: 4 x 3  
##   X__1      a      b  
##   <chr> <dbl> <dbl>  
## 1 1      1      4  
## 2 2      2      3  
## 3 3      3      2
```


SPSS-Dateien importieren

- Bibliothek `haven` - Import und Export von 'SPSS', 'Stata' und 'SAS' Dateien
- das Ergebnis dieses Importkommandos ist ein `tibble`

```
library(haven)
dataset <- read_sav("../data/ZA5666_v1-0-0.sav")
```

Daten aus dem Web importieren

Dateien können auch direkt aus dem Internet importiert werden:

```
library(foreign)
link <- "http://www.statistik.at/web_de/static/
mz_2013_sds_-_datensatz_080469.sav"

?read.spss
Dat <- read.spss(link,to.data.frame=T)
```

Importieren von stata Dateien

- Mit `read.dta13` können Stata-Dateien ab Version 13 (und höher) importiert werden.

```
library(readstata13)
dat_stata <- read.dta13("../data/ZA5666_v1-0-0_Stata14.dta")
```

Import von stata Dateien - ältere Versionen

```
library(foreign)
dat_stata12 <- read.dta("../data/ZA5666_v1-0-0_Stata12.dta")
```

- Einführung in den Import mit R (**is.R**)

Die Bibliothek readstata13

readstata13 {readstata13}

R Documentation

Import Stata Data Files

Description

Function to read the Stata file format into a `data.frame`.

Note

If you catch a bug, please do not sue us, we do not have any money.

Author(s)

Marvin Garbuszus jan.garbuszus@ruhr-uni-bochum.de

Sebastian Jeworutzki sebastian.jeworutzki@ruhr-uni-bochum.de

See Also

[read.dta](#) and [memisc](#) for `dta` files from Stata Versions < 13

Importieren - GESIS Panel-Daten

```
library(readstata13)
```

```
datf <- read.dta13("../data/ZA5666_v1-0-0_Stata14.dta",  
                  convert.factors = F)
```

```
head(datf$bbzc007a)
```

```
## [1] 1 1 1 1 3 1
```

Zum Vergleich - Import ohne dieses Argument

```
dat <- read.dta13("../data/ZA5666_v1-0-0_Stata14.dta")
```

```
head(dat$bbzc007a)
```

```
## [1] Nein
```

```
Nein
```

```
Nein
```

```
Nein
```

```
Ja
```

Stata-Attribute bekommen

```
att_dat <- attributes(dat)
head(names(att_dat))
```

```
## [1] "row.names"  "names"      "datalabel"  "time.stamp" "f"
## [6] "types"
```

Beispiel: die Variablennamen

```
head(att_dat$var.labels)
```

```
## [1] "Personen ID - Campus File"
## [2] "Studiennummer des Archivs"
## [3] "Versionskennung und -datum des Archivs"
## [4] "doi"
## [5] "Zufriedenheit Leben in Wohnort"
## [6] "Zufriedenheit Leben in Deutschland"
```

Sich einen ersten Überblick verschaffen

View(datf)

	z000001z Personen ID - Campus File	z000002z Studiennummer des Archivs	z000003z Versionskennung und -datum des Archivs	z000005z doi	a11c019a Zufriedenheit Leben in Wohnort	a11c020a Zufriedenheit
1	198431880	ZA5666	1-0-0 2017-06-20	10.4232/1.12749		1
2	436122330	ZA5666	1-0-0 2017-06-20	10.4232/1.12749		1
3	856844220	ZA5666	1-0-0 2017-06-20	10.4232/1.12749		2
4	117346660	ZA5666	1-0-0 2017-06-20	10.4232/1.12749		1
5	943433330	ZA5666	1-0-0 2017-06-20	10.4232/1.12749		1

- Das gleiche können Sie in RStudio erhalten, wenn Sie auf das Datensatzsymbol im Umgebungsmenü klicken.

Die Bibliothek rio

```
install.packages("rio")
```

```
library("rio")  
x <- import("../data/ZA5666_v1-0-0.csv")  
y <- import("../data/ZA5666_v1-0-0_Stata12.dta")  
z <- import("../data/ZA5666_v1-0-0_Stata14.dta")
```

- **rio: Ein Schweizer Offiziersmesser für Data I/O**

Das Paket Hmisc

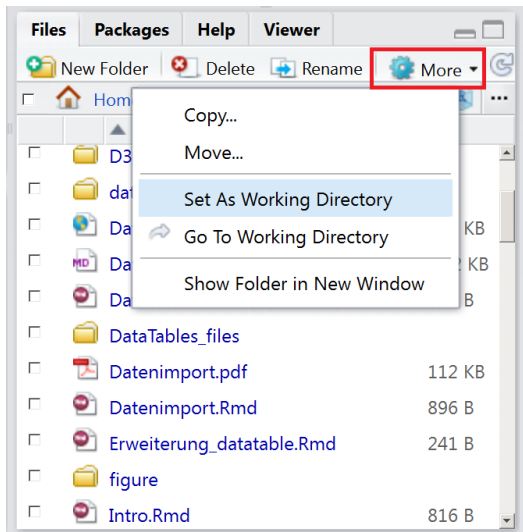
Für SPSS und SAS würde ich das Hmisc-Paket aus Gründen der Einfachheit und Funktionalität empfehlen.

```
library(Hmisc)
mydata <- spss.get("c:/mydata.por", use.value.labels=TRUE)
# last option converts value labels to R factors
```


SAS Daten importieren

```
mydata <- sasxport.get("c:/mydata.xpt")
# character variables are converted to R factors
```

Das Arbeitsverzeichnis



- Wenn sich die Daten auf einem anderen Laufwerk in Windows befinden



Das Arbeitsverzeichnis II

Auf diese Weise können Sie herausfinden, in welchem Verzeichnis Sie sich gerade befinden.

```
getwd()
```

So können Sie das Arbeitsverzeichnis ändern:

Sie legen ein Objekt an, in dem Sie den Pfad speichern:

```
main.path <- "C:/" # Example for Windows  
main.path <- "/users/Name/" # Example for Mac  
main.path <- "/home/user/" # Example for Linux
```

Und dann ändert man den Pfad mit `setwd()`.

```
setwd(main.path)
```

Unter Windows ist es wichtig Slashes anstelle von Backslashes zu verwenden

Arbeitsverzeichnis wechseln

- Man kann auch die Tabulatortaste verwenden, um die automatische Vervollständigung zu erhalten.

```
getwd()
```

```
## [1] "D:/Daten/GitHub/r_intro_gp18/slides"
```

```
setwd("../")  
getwd()
```

```
## [1] "D:/Daten/GitHub/r_intro_gp18"
```


Eingebaute Datensätze

- Häufig wird ein Beispieldatensatz zur Verfügung gestellt, um die Funktionalität eines Pakets zu zeigen.
- Diese Datensätze können mit dem Befehl `data` geladen werden.

```
data(iris)
```

- Es gibt auch ein **RStudio-Add-In**, das hilft, einen Datensatz zu finden.

```
install.packages("datasets.load")
```



Daten einfügen

- RStudio Addin um Daten einzufügen

```
devtools::install_github("lbusett/insert_table")
```

Insert Table Add-In

Cancel

Select output format and edit the Table if you wish so

Done

Select Table Name

my_tbl

Select Output Format

None

Edit Table or cut and paste from spreadsheet

* The first row will be used as column names.

* Right click to add more lines or columns

☒ Use first row as column names. (If unchecked, 'Col_1', 'Col_2', etc. are used)

1	a	v		c
2				
3				

A4A Übung - Importieren der Daten des GESIS-Panels

- Bitte importiert die GESIS-Paneldaten (Version stata 14) mit einem geeigneten Befehl