## **B2** - Graphics intro

Jan-Philipp Kolb

16 Oktober 2018

## Eine Graphik sagt mehr als 1000 Worte.

#### Aussagen zu Graphen in R

- Die grafische Datenanalyse ist großartig.
- Gute Graphiken können zu einem besseren Verständnis beitragen.
- Die Erzeugung eines Plot ist einfach.
- Einen guten Plot zu erstellen, kann sehr lange dauern.
- Das Erstellen von Plots mit R macht Spaß.
- Mit R erstellte Diagramme haben eine hohe Qualität.
- Fast jedes Graphikformat wird von R unterstützt.
- Eine große Anzahl von Exportformaten ist in R verfügbar.

## Nicht alle Diagramme sind gleich.

- Das Basispaket enthält bereits eine Vielzahl von Plotfunktionen.
- Andere Pakete wie lattice, ggplot2, etc. erweitern diese Funktionalität.

#### Handbücher, die weit über diese Einführung hinausgehen:

- Murrell, P (2006): R Graphics.
- R Development Core Group Graphiken mit R
- Wiki zu R Programmierung/Graphiken
- Martin Meermeyer Creating Reproducible Publication Quality Graphics with R: A Tutorial
- Institute for Quantitative Social Science at Harvard R Graphik Tutorial

## Task View für Graphiken

CRAN Task View: Graphic Displays & Dynamic Graphics & Graphic Devices & Visualization

Maintainer: Nicholas Lewin-Koh Contact: nikko at hailmail.net Version: 2015-01-07

URL: https://CRAN.R-project.org/view=Graphics

R is rich with facilities for creating and developing interesting graphics. Base R contains functionality for many plot types including coplots, mosaic plots, biplots, and the list goes on. There are devices such as postscript, pug, joge and pdf for outputting graphics as well as device drivers for all platforms running R. <u>lattice</u> and grid are supplied with RFs recommended packages and are included in every binary distribution. <u>lattice</u> is an R implementation of William Cleveland's relilis graphics, while grid defines a much more flexible graphics environment than the base R graphics.

R\ base graphics are implemented in the same way as in the S3 system developed by Becker, Chambers, and Wilks. There is a strict device, which is treated as a static canvas and objects are drawn on the device through R\ plotting commands. The device has a set of global parameters use has margins and largours which can be manipulated by the user using party commands. The R graphics enime does not maintain a user visible graphics ilst, and there is no system of double buffering, so objects cannot be easily edited without redrawing a whole plot. This situation may change in R 2.7x, where developers are working on double buffering for 8 devices. Even so, the base R graphics on my produce many plots with extremely thin graphics in many specialized instances.

One can quickly run into trouble with Rs base graphic system if one wants to design complex layouts where scaling is minimation upropely on resizing, nested graphs are desired or more interactivity is needed. grid was designed by Paul Murrell to overcome some of these limitations and as a restill packages like latting, expelled. 200 or health use grid for the underlying printines. When using plots designed with grid one needs to keep in mind that grid is based on a system of viewports and graphic objects. To add objects one needs to use grid commands, e.g., grid, polygon() rather than polygon(). Also grid maintains a stack of viewports from the device and one needs to be such seem the desired viewout for the device and one needs to be such seem the desired viewort is from the device and one needs to a fast of the vieworth from the device and one needs to take grid with off and the desired vieworth from the device and one needs to take grid with off as vieworth from the device and one needs to take grid with off as vieworth from the device and one needs to take grid with grid as vieworth.

The graphics packages in R can be organized roughly into the following topics, which range from the more user oriented at the top to the more developer oriented at the bottom. The categories are not mutually exclusive but are for the convenience of presentation:

https://cran.r-project.org/web/views/Graphics.html

## **GESIS** Panel Daten importieren

 Zum importieren nutzen wir die Funktion read.dta13 aus dem Paket readstata13

```
dat <- readstata13::read.dta13(
   "../data/ZA5666_v1-0-0_Stata14.dta")</pre>
```

## Geschätzte Dauer (bfzq020a)

### Wie lange haben Sie gebraucht, um den Fragebogen auszufüllen?

```
dat <- readstata13::read.dta13("ZA5666_v1-0-0_Stata14.dta")
summary(dat$duration)</pre>
```

```
dat$duration <- as.numeric(dat$bfzq020a)</pre>
```

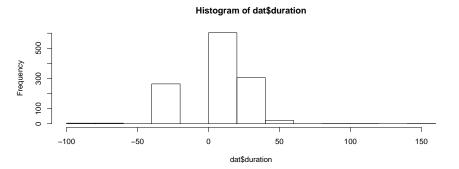
```
## Min. 1st Qu. Median Mean 3rd Qu. Max. NA's
## -99.00 10.00 16.00 10.02 25.00 156.00 16
```

## Histogramm - Die Funktion hist()

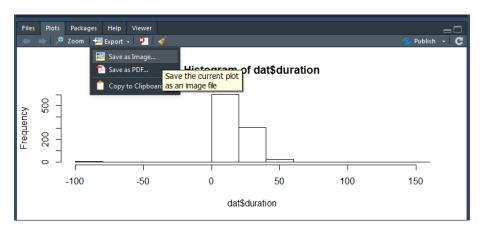
Wir erstellen ein Histogramm der Variablen Dauer:

?hist

hist(dat\$duration)



## **Export mit Rstudio**



## Befehl zum Speichern der Grafik

Alternativ auch mit den Befehlen png, pdf oder jpeg zum Beispiel.

```
png("Histogramm.png")
  hist(dat$duration)
dev.off()
pdf("Histogramm.pdf")
  hist(dat$duration)
dev.off()
jpeg("Histogramm.jpeg")
  hist(dat$duration)
dev.off()
```

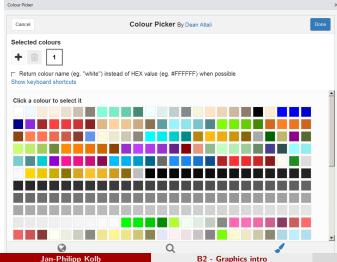
## Histogramm

- Der Befehl hist() zeichnet ein Histogramm.
- Mindestens ein Beobachtungsvektor muss an die Funktion übergeben werden.
- hist() hat viele weitere Argumente, die alle (sinnvolle) Standardwerte haben.

```
hist(dat$duration,col="blue",
    main="Duration of interview",ylab="Frequency",
    xlab="Duration")
```

## Rstudio Addin colourpicker

#### install.packages("colourpicker")



## Weitere Argumente:

?plot
# or
?par

#### **Graphical Parameters**

iha

The value of adj determines the way in which text strings are justified in <u>text</u>, <u>mtext</u> and <u>title</u>. A value of 0 produces left-justified text, 0.5 (the default) centered text and 1 right-justified text. (Any value in [0, 1] is allowed, and on most devices values outside that interval will also work.)

Note that the adj argument of text also allows adj = c(x, y) for different adjustment in x- and y- directions. Note that whereas for text it refers to positioning of text about a point, for mtext and title it controls placement within the plot or device region.

ann

If set to FALSE, high-level plotting functions calling plot.default do not annotate the plots they produce with axis titles and overall titles. The default is to do annotation.

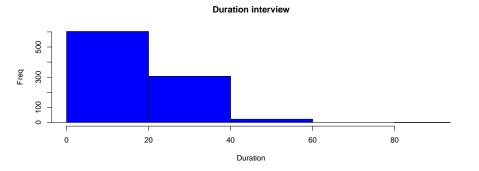
ask

logical. If TRUE (and the R session is interactive) the user is asked for input, before a new figure is drawn. As this applies to the device, it also affects output by packages grid and lattice. It can be set even on non-screen devices but may have no effect there.

This not really a graphics parameter, and its use is deprecated in favour of devAskNewPage

## Das xlim Argument

```
hist(dat$duration,col="blue",
    main="Duration interview",ylab="Freq", xlab="Duration",
    xlim=c(0,90))
```



## Das breaks Argument

• Während die vorherigen Argumente für viele Grafikfunktionen gelten, gilt das Folgende hauptsächlich für Histogramme:

```
hist(dat$duration,col="red",
    main="Duration of interview", xlab="Duration",
    xlim=c(0,90),breaks=60)
```

Mit breaks kann man die Zahl der Balken kontrollieren:

## Tabellieren und barplot

```
sex <- as.character(dat$a11d054a)
sex[dat$a11d054a=="Männlich"] <- "m"
sex[dat$a11d054a=="Weiblich"] <- "f"</pre>
```

- Der Befehl barplot() erzeugt einen Barplot aus einer Frequenztabelle.
- Wir erhalten die Tabelle mit dem folgenden Befehl:

```
tab_sex <- table(sex)
```

```
barplot(tab_sex)
```

## Mehr Farbe:

barplot(tab\_sex,col=rgb(0,0,1))

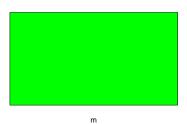




## Grüne Farbe

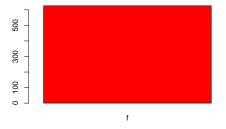
barplot(tab\_sex,col=rgb(0,1,0))





### Rote Farbe

barplot(tab\_sex,col=rgb(1,0,0))

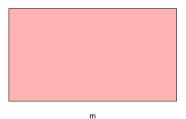




## **Transparent**

```
barplot(tab_sex,col=rgb(1,0,0,.3))
```





#### Eine zweidimensionale Tabelle

Internet-Suche nach Infos: Freunde (bbzc024a) und Geschlecht (a11d054a)

• Wenn das übergebene Tabellenobjekt zweidimensional ist, wird ein bedingter Barplot erstellt.

```
table(dat$bbzc024a,sex)
```

```
##
                        sex
##
                           f
                               m
##
     Item nonresponse
                          25 27
                          66 50
##
     Missing by filter
##
     Not reached
##
     Unit nonresponse
                          79 91
##
     Not in panel
                               6
##
     Nein
                         220 213
##
     Ja
                         231 208
```

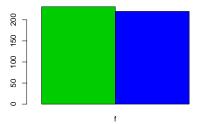
#### Fehlende Werte rekodieren

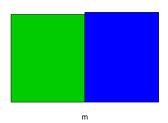
```
transform miss <- function(x){</pre>
  x[x\%in\%c(-11,-22,-33,-44,-55,-66,-77,-88,-99,-111)] < NA
  x[x%in%c("Item nonresponse", "Missing by filter",
           "Not reached", "Unit nonresponse",
           "Not in panel")] <- NA
  return(x)
Inetfriends <- as.character(transform_miss(dat$bbzc024a))</pre>
(tab2dim <- table(Inetfriends, sex))
##
              sex
## Tnetfriends f
##
          Ja 231 208
##
          Nein 220 213
```

## Bedingter barplot

barplot(tab2dim,col=1:2)

barplot(tab2dim,col=3:4,beside=T)



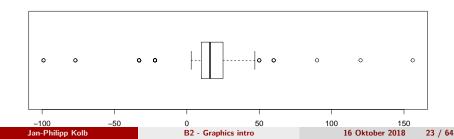


## **Horizontaler Boxplot**

- Ein einfacher **boxplot** kann mit boxplot() erstellt werden.
- Für den Befehl boxplot() muss mindestens ein Beobachtungsvektor übergeben werden.

#### ?boxplot

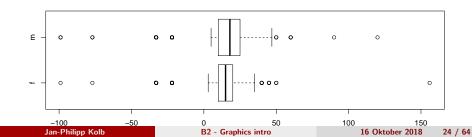
```
boxplot(dat$duration,horizontal=TRUE)
```



## **Gruppierte Boxplots**

- Ein sehr einfacher Weg, sich einen ersten Eindruck von bedingten Verteilungen zu verschaffen, ist über sogenannte gruppierte Boxplots.
- Dazu muss ein sogenanntes Formelobjekt an die Funktion boxplot() übergeben werden.
- Die bedingte Variable befindet sich auf der rechten Seite einer Tilde.

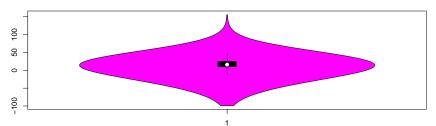
```
boxplot(dat$duration~sex,horizontal=TRUE)
```



## Boxplot Alternativen - vioplot

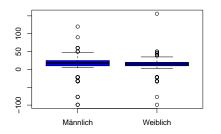
- Baut auf dem boxplot auf Zusatzinformationen zur Dichte
- Die Dichte wird mit der Kernel-Methode berechnet.
- Je weiter die Ausdehnung, desto höher ist die Dichte an dieser Stelle.
- Weißer Punkt Medianwert

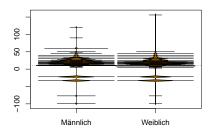
```
library(vioplot)
vioplot(na.omit(dat$duration))
```



## Alternativen zum boxplot()

```
library(beanplot)
par(mfrow = c(1,2))
boxplot(dat$duration~dat$a11d054a,data=dat,col="blue")
beanplot(dat$duration~dat$a11d054a,data=dat,col="orange")
```



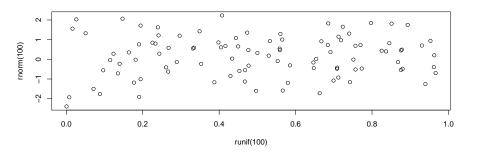


# Bedingte, bi- und multivariate Graphiken - Scatterplots

- Ein einfaches Streudiagramm kann mit der Funktion plot() erstellt werden.
- Um ein Scatterplot zu erstellen, müssen x und y als Beobachtungsvektoren übergeben werden.
- Argument col Farbe als Zeichen oder numerisch
- Argument pch Plotsymbol als Zeichen oder numerisch
- Achsenbeschriftung wird mit xlab und ylab definiert.

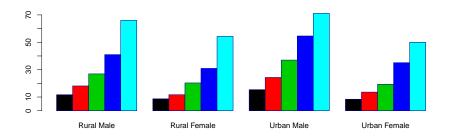
## **Scatterplot**

plot(runif(100),rnorm(100))



## B2A Übung - einfache Grafiken

 Laden Sie den Datensatz VADeaths und erstellen Sie die folgende Darstellung:

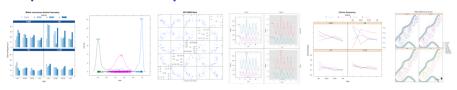


#### Das lattice-Paket

#### Definition einer lattice Graphik

It is designed to meet most typical graphics needs with minimal tuning, but can also be easily extended to handle most nonstandard requirements.

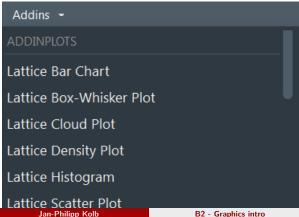
#### Beispiele für lattice Graphiken



#### Ein weiteres Addin für RStudio

• das addinplots-Paket installieren - den Datensatz markieren, der visualisiert werden soll, und einen Plottyp wählen:

devtools::install github("homerhanumat/addinplots")



## Benutzer Interface für addinplots



#### iris # Beispieldatensatz

Jan-Philipp Kolb B2 - Graphics intro 16 Oktober 2018 32 / 64

## Ein Beispieldatensatz - Testergebnisse bei A-level Chemie Test aus dem Jahr 1997

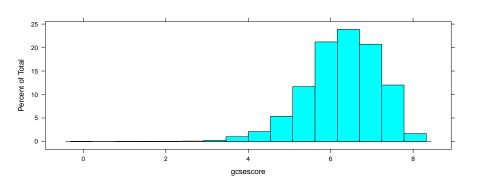
```
library("mlmRev")
data(Chem97)
```

variables	categories
lea	Local Education Authority
school	School identifier
student	Student identifier
score	Point score on A-level Chemistry in 1997
gender	Student's gender
age	Age in month, centred at 222 months or 18.5 years
gcsescore	Average GCSE score of individual
gcsecnt	$\label{eq:conditional} \mbox{Average GCSE score of individual, centered at mean}$

33 / 64

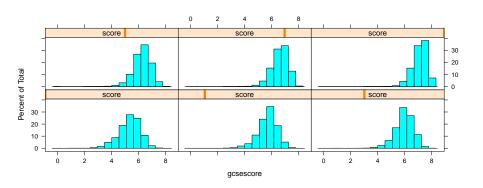
## Histogramm mit lattice

```
library("lattice")
histogram(~ gcsescore, data = Chem97)
```



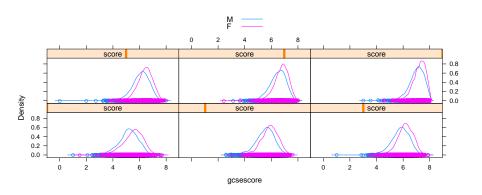
## Mehr Histogramme mit lattice

histogram(~ gcsescore | score,data = Chem97)



## Die Dichte plotten mit einer Legende

```
densityplot(~ gcsescore | score, Chem97,
    groups=gender,auto.key=TRUE)
```

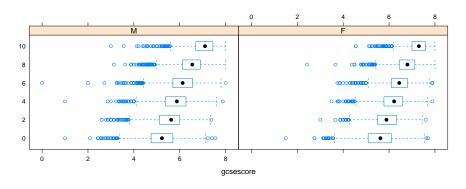


#### Einführung in das lattice Paket

### Einen Boxplot mit lattice erzeugen

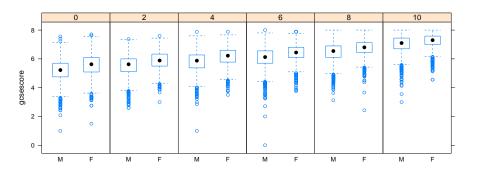
```
Chem97$score <- as.factor(Chem97$score)</pre>
```

```
bwplot(score ~ gcsescore | gender, Chem97)
```

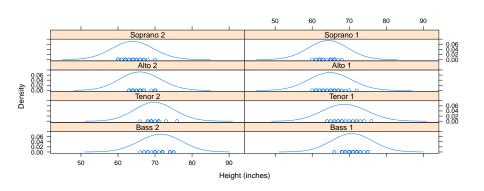


# Bedingte Boxplots mit lattice erzeugen

```
bwplot(gcsescore ~ gender | score, Chem97,
layout = c(6, 1))
```

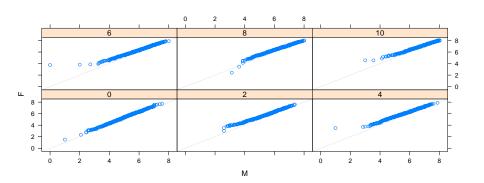


### Ein densityplot

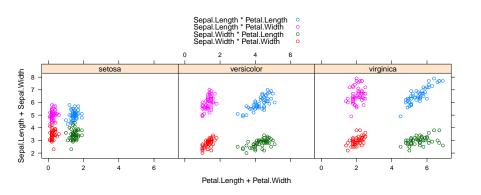


## Bivariate Plots - Quantile-Quantile Plot

qq(gender ~ gcsescore | score, Chem97)

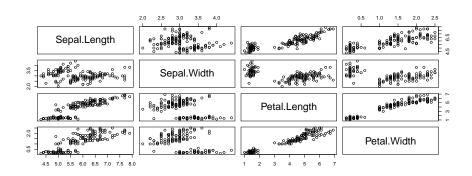


### Scatterplot mit lattice - xyplot

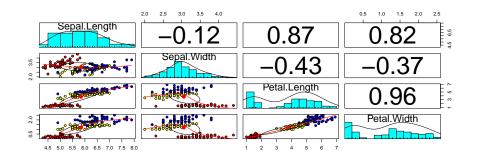


# Zusammenhang zwischen Variablen - pairs Plot

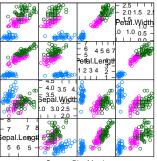
pairs(iris[,1:4])



### Den pairsPlot erweitert



## Multivariate Plots - splom



Scatter Plot Matrix

## Mehr Argumente im splom Befehl

## Der Beispieldatensatz BankWages

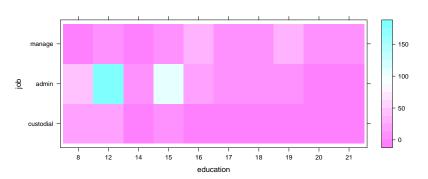
```
install.packages("AER")
library("AER")
data(BankWages)
```

```
head(BankWages)
```

```
##
        job education gender minority
    manage
                   15
                        male
                                   no
     admin
                   16 male
                                   no
## 3 admin
                   12 female
                                   no
    admin
                      female
## 4
                                   no
## 5 admin
                   15 male
                                   no
## 6
     admin
                   15 male
                                   no
```

### levelplot

education in Jahren



## Nutzung sozialer Netzwerke: Facebook (bbzc041a)

 1 - Nein, bin kein Mitglied; 2 - Ja, nutze es aber nie; 3 - Ja, nutze es manchmal; 4 - Ja, nutze es oft

```
facebook <- transform_miss(datf$bbzc041a)
table(facebook)</pre>
```

```
## facebook
## 1 2 3 4
## 512 57 178 188
```

## Nutzung sozialer Netzwerke: Twitter (bbzc042a)

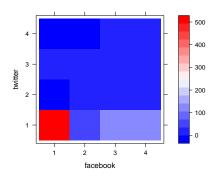
 1 - Nein, bin kein Mitglied; 2 - Ja, nutze es aber nie; 3 - Ja, nutze es manchmal; 4 - Ja, nutze es oft

```
twitter <- as.character(transform_miss(datf$bbzc042a))
table(twitter)</pre>
```

```
## twitter
## 1 2 3 4
## 791 38 20 6
```

### levelplot mit GESIS Panel Daten

```
levelplot(table(facebook,twitter),
col.regions=colorRampPalette(c("blue","white","red")))
```



# **Internet Nutzung (GESIS Panel)**

• a11c035a: Häufigkeit private Internetnutzung: Tischcomputer

```
internet <- transform_miss(datf$a11c035a)</pre>
```

• a11c037a: Häufigkeit private Internetnutzung: Smartphone

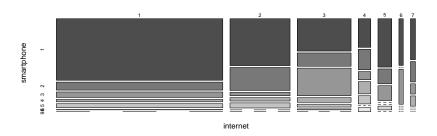
```
smartphone <- transform_miss(datf$a11c037a)</pre>
```

1 - Mehrmals täglich; 2 - Etwa einmal täglich; 3 - Mehrmals die Woche; 4 - Etwa einmal die Woche; 5 - Seltener; 6 - Nie; 98 - Weiß nicht

```
tab2 <- table(internet,smartphone)</pre>
```

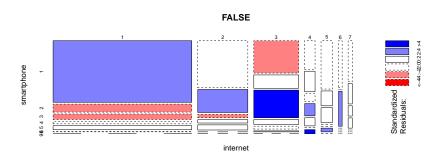
# Zusammenhang - kategoriale Variablen

```
mosaicplot(tab2, color = TRUE, main="")
```



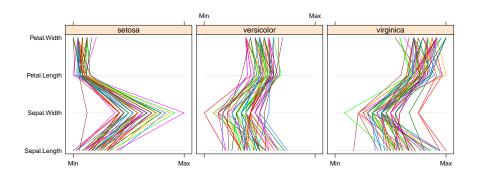
# Die Flächen werden anhand der Residuen eingefärbt:

mosaicplot(tab2, main=F,shade = TRUE)



### parallelplot()

#### parallelplot(~iris[,1:4] | Species, iris)

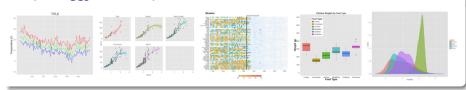


### Das ggplot2 Paket

#### Einführung ggplot2

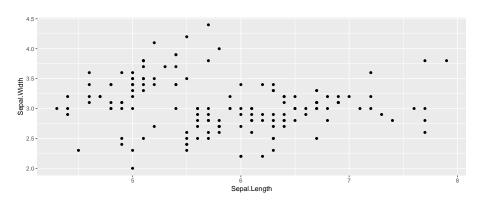
The ggplot2 package, created by Hadley Wickham, offers a powerful graphics language for creating elegant and complex plots. Its popularity in the R community has exploded in recent years. Origianlly based on Leland Wilkinson's The Grammar of Graphics, ggplot2 allows you to create graphs that represent both univariate and multivariate numerical and categorical data in a straightforward manner.

#### Beispiele ggplot2 Graphiken



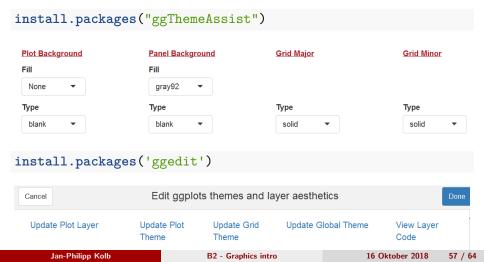
### Ein erstes Beispiel ggplot2

```
library(ggplot2)
ggplot(iris, aes(x=Sepal.Length, y=Sepal.Width)) +
  geom_point()
```



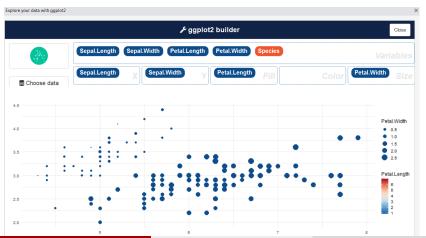
### Einige schöne Rstudio Addins

• Eine ggplot Grafik muss im Quellcode markiert werden, um die folgenden Addins zu verwenden



# RStudio Addin zum Erzeugen von ggplot2 Graphiken

devtools::install\_github("dreamRs/esquisse")

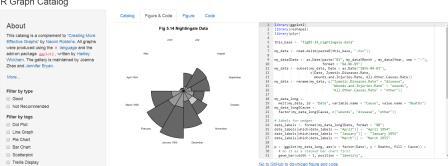


# Shiny App - R Graphik Katalog

#### http://shinyapps.stat.ubc.ca/r-graph-catalog/

#### R Graph Catalog

☐ Histogram



16 Oktober 2018

## Ein Beispieldatensatz zu Diamanten

A dataset containing the prices and other attributes of almost 54,000 diamonds.

- price price in US dollars (\$326-\$18,823)
- carat weight of the diamond (0.2-5.01)
- cut quality of the cut (Fair, Good, Very Good, Premium, Ideal)
- color diamond colour, from J (worst) to D (best)
- clarity a measurement of how clear the diamond is (I1 (worst), SI2, SI1, VS2, VS1, VVS2, VVS1, IF (best))

#### data(diamonds)

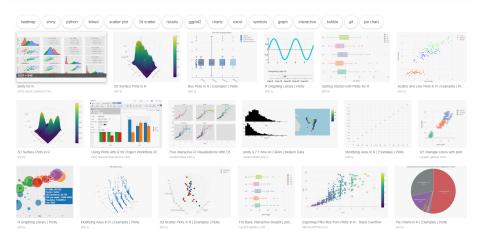
• Der Datensatz ist zu groß für unsere Anwendungszwecke:

```
d <- diamonds[sample(nrow(diamonds), 1000), ]</pre>
```

### Das Paket plotly

Create Interactive Web Graphics via 'plotly.js'

#### library(plotly)



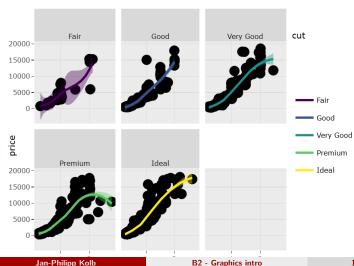
## Interaktivität hinzufügen

```
p <- ggplot(data = d, aes(x = carat, y = price)) +
  geom_point(aes(text = clarity, size = 4)) +
  geom_smooth(aes(colour = cut, fill = cut))+
  facet_wrap(~ cut)</pre>
```

#### Es wird eine ggplot Graphik erzeugt

# Das Ergebnis - eine interaktive Graphik

#### ggplotly(p)



#### Links

- J H Maindonald Lattice and Other Graphics in R
- Deepayan Sarkar An introduction to R lattice lab
- Flowingdata Comparing ggplot2 and R Base Graphics
- Quick R ggplot2
- Top 50 ggplot2 Visualizations
- Bioconductor R manual with an extensive part on graphics
- Shiny app to visualize ggplot2 internals
- Shiny app for interactive plot editing