

B3 - Linear Regression

Jan-Philipp Kolb

16 Oktober 2018

Gute Literatur für lineare Regression in R

J H Maindonald - Using R for Data Analysis and Graphics Introduction, Code and Commentary

- Introduction to R
- Data analysis
- Statistical models
- Inference concepts
- Regression with one predictor
- Multiple linear regression
- Extending the linear model
- ...

Variablen im mtcars Datensatz

Hilfe File für den roller Datensatz:

```
?mtcars
```



- mpg - Meilen/(US) Gallone
- cyl - Anzahl der Zylinder

Datensatz mtcars

	mpg	cyl	disp	hp	drat	wt	qsec	vs	a
Mazda RX4	21.0	6	160.0	110	3.90	2.620	16.46	0	
Mazda RX4 Wag	21.0	6	160.0	110	3.90	2.875	17.02	0	
Datsun 710	22.8	4	108.0	93	3.85	2.320	18.61	1	
Hornet 4 Drive	21.4	6	258.0	110	3.08	3.215	19.44	1	
Hornet Sportabout	18.7	8	360.0	175	3.15	3.440	17.02	0	
Valiant	18.1	6	225.0	105	2.76	3.460	20.22	1	
Duster 360	14.3	8	360.0	245	3.21	3.570	15.84	0	
Merc 240D	24.4	4	146.7	62	3.69	3.190	20.00	1	
Merc 230	22.8	4	140.8	95	3.92	3.150	22.90	1	
Merc 280	19.2	6	167.6	123	3.92	3.440	18.30	1	
Merc 280C	17.8	6	167.6	123	3.92	3.440	18.90	1	
Merc 450SE	16.4	8	275.8	180	3.07	4.070	17.40	0	
Merc 450SL	17.3	8	275.8	180	3.07	3.730	17.60	0	
Merc 450SLC	15.2	8	275.8	180	3.07	3.780	18.00	0	
Cadillac Fleetwood	10.4	8	472.0	205	2.02	5.250	17.02	0	

Verteilungen von zwei Variablen aus dem Datensatz `mtcars`

```
par(mfrow=c(1,2))  
plot(density(mtcars$wt)); plot(density(mtcars$mpg))
```



Ein einfaches Regressionsmodell

Abhängige Variable - Meilen pro Gallone (mpg)

Unabhängige Variable - Gewicht (wt)

```
m1 <- lm(mpg ~ wt, data=mtcars)
```

```
m1
```

```
##  
## Call:  
## lm(formula = mpg ~ wt, data = mtcars)  
##  
## Coefficients:  
## (Intercept)          wt  
##      37.285      -5.344
```

Die Modell Zusammenfassung:

```
summary(m1)
```

```
##  
## Call:  
## lm(formula = mpg ~ wt, data = mtcars)
```

```
##  
## Residuals:  
##      Min       1Q   Median       3Q      Max  
## -4.5432 -2.3647 -0.1252  1.4096  6.8727
```

```
##  
## Coefficients:  
##              Estimate Std. Error t value Pr(>|t|)  
## (Intercept)  37.2851     1.8776   19.858 < 2e-16 ***  
## wt          -5.3445     0.5591   -9.559 1.29e-10 ***
```

```
## ---  
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Die Modellformel

Modell ohne Achsenabschnitt

```
m2 <- lm(mpg ~ - 1 + wt,data=mtcars)
summary(m2)$coefficients
```

```
##      Estimate Std. Error  t value    Pr(>|t|)
## wt  5.291624   0.5931801  8.920771 4.55314e-10
```

Weitere Variablen hinzufügen

```
m3 <- lm(mpg ~ wt + cyl,data=mtcars)
summary(m3)$coefficients
```

```
##              Estimate Std. Error  t value    Pr(>|t|)
## (Intercept) 39.686261   1.7149840 23.140893 3.043182e-20
## wt          -3.190972   0.7569065 -4.215808 2.220200e-04
## cyl         -1.507795   0.4146883 -3.635972 1.064282e-03
```


Weitere Möglichkeiten, die Formel zu spezifizieren

Interaktionseffekt

effect of cyl and interaction effect:

```
m3a<-lm(mpg~wt*cyl,data=mtcars)
```

only interaction effect:

```
m3b<-lm(mpg~wt:cyl,data=mtcars)
```

Den Logarithmus nehmen

```
m3d<-lm(mpg~log(wt),data=mtcars)
```

Ein Modell mit Interaktionseffekt

Variable disp - Hubraum


```
m3d<-lm(mpg~wt*disp,data=mtcars)
m3dsum <- summary(m3d)
m3dsum$coefficients
```

	Estimate	Std. Error	t value	Pr(> t)
## (Intercept)	44.08199770	3.123062627	14.114990	2.955567e-14
## wt	-6.49567966	1.313382622	-4.945763	3.216705e-05
## disp	-0.05635816	0.013238696	-4.257078	2.101721e-04
## wt:disp	0.01170542	0.003255102	3.596022	1.226988e-03

Interaktionen untersuchen

jtools - Analysis and Presentation of Social Scientific Data

```
library(jtools)  
interact_plot(m3d, pred = "wt", modx = "disp")
```



- Wenn Interaktions-Variabel stetig (hier disp) erhält man drei Linien:

Das R-Paket **interplot**

Plot the Effects of Variables in Interaction Terms

```
library(interplot)
```

- Eine detailliertere Erklärung findet man in der **Interplot** Vignette

interplot: Plot the Effects of Variables in Interaction Terms

Frederick Solt and Yue Hu


2018-06-30

Interaction is a powerful tool to test conditional effects of one variable on the contribution of another variable to the dependent variable and has been extensively applied in the empirical research of social science since the 1970s (Wright Jr 1976). Unfortunately, the nonlinear nature determines that the statistical estimate of an interactive effect cannot be interpreted as straightforward as the coefficient of a regular regression parameter. Let's use a simple example to illustrate this point: The following model use an interaction term to test the conditional effect of Z on X's contribution (or the conditional effect of X on Z's contribution) to the variance of Y.

Das R-Paket interplot

- Der Effekt wird auf der y Achse abgetragen - wt auf der x-Achse

```
interplot(m = m3a, var1 = "wt", var2 = "cyl", hist = TRUE)
```



Beispiel: Objekt Orientierung

- m3 ist nun ein spezielles Regressionsobjekt
- Verschiedene Funktionen können auf dieses Objekt angewendet werden.

```
predict(m3) # Prediction  
resid(m3)  # Residuals
```

##	Mazda RX4	Mazda RX4 Wag	Datsun 710	Hornet
##	22.27914	21.46545	26.25203	
##	Hornet Sportabout	Valiant		
##	16.64696	19.59873		

##	Mazda RX4	Mazda RX4 Wag	Datsun 710	Hornet
##	-1.2791447	-0.4654468	-3.4520262	
##	Hornet Sportabout	Valiant		
##	2.0530424	-1.4987281		

Eine Modellvorhersage machen

```
pre <- predict(m1)
head(mtcars$mpg)
```

```
## [1] 21.0 21.0 22.8 21.4 18.7 18.1
```


```
head(pre)
```

```
##           Mazda RX4           Mazda RX4 Wag           Datsun 710           Ho
##           23.28261           21.91977           24.88595
## Hornet Sportabout           Valiant
##           18.90014           18.79325
```

Residuenplot - Modellannahmen verletzt?


- Gibt es ein Muster in der Abweichung von der Linie

```
plot(m3,1)
```



Residuenplot


```
plot(m3,2)
```



- Wenn die Residuen normalverteilt sind, dann sollten sie auf der gleichen Linie liegen.

Regressionsdiagnostik mit Basis-R



```
plot(mtcars$wt,mtcars$mpg)
abline(m1)
segments(mtcars$wt, mtcars$mpg, mtcars$wt, pre, col="red")
```



Das visreg-Paket

```
install.packages("visreg")
```


```
library(visreg)
```



Das visreg-Paket

- Das Default-Argument für `type` ist `conditional`.
- Scatterplot von `mpg` und `wt` mit Regressionslinie und Konfidenzbändern


```
visreg(m1, "wt", type = "conditional")
```



Visualisierung mit visreg

- Zweites Argument - Spezifikation der Kovariaten in der Graphik
- Das Diagramm zeigt die Auswirkung auf den erwarteten Wert des Regressors, wenn die Variable x von einem Referenzpunkt auf der x -Achse wegbewegt wird (bei numerischen Variablen der Mittelwert).

```
visreg(m1, "wt", type = "contrast")
```



Regression mit Faktoren



- Die Effekte von Faktoren können auch mit visreg visualisiert werden:

```
mtcars$cyl <- as.factor(mtcars$cyl)
m4 <- lm(mpg ~ cyl + wt, data = mtcars)
# summary(m4)
```

	Estimate	Std. Error	t value	Pr(> t)
## (Intercept)	33.990794	1.8877934	18.005569	6.257246e-17
## cyl6	-4.255582	1.3860728	-3.070244	4.717834e-03
## cyl8	-6.070860	1.6522878	-3.674214	9.991893e-04
## wt	-3.205613	0.7538957	-4.252065	2.130435e-04

Effekte von Faktoren

```
par(mfrow=c(1,2))  
visreg(m4, "cyl", type = "contrast")  
visreg(m4, "cyl", type = "conditional")
```




Das Paket visreg - Interaktionen

```
m5 <- lm(mpg ~ cyl*wt, data = mtcars)
# summary(m5)
```

##	Estimate	Std. Error	t value	Pr(> t)
## (Intercept)	39.571196	3.193940	12.3894599	2.058359e-12
## cyl6	-11.162351	9.355346	-1.1931522	2.435843e-01
## cyl8	-15.703167	4.839464	-3.2448150	3.223216e-03
## wt	-5.647025	1.359498	-4.1537586	3.127578e-04
## cyl6:wt	2.866919	3.117330	0.9196716	3.661987e-01
## cyl8:wt	3.454587	1.627261	2.1229458	4.344037e-02

Den Graphikoutput mit layout kontrollieren


```
visreg(m5, "wt", by = "cyl", layout=c(3,1))
```



Das Paket visreg - Interaktionseffekte übereinander legen


```
m6 <- lm(mpg ~ hp + wt * cyl, data = mtcars)
```

```
visreg(m6, "wt", by="cyl", overlay=TRUE, partial=FALSE)
```




Das Paket visreg - visreg2d

```
visreg2d(m6, "wt", "hp", plot.type = "image")
```



Das Paket visreg - surface

```
visreg2d(m6, "wt", "hp", plot.type = "persp")
```



B3A Aufgabe lineare Regression

Der Datensatz `toycars` beschreibt die Route von drei Spielzeugautos, die Rampen in verschiedenen Winkeln absteigen.

- `angle`: Rampenwinkel
 - `distance`: Entfernung die von dem Spielzeugauto zurück gelegt wird.
 - `car`: Autotyp (1, 2 or 3)
- 1 Lese den Datensatz `toycars` ein und konvertiere die Variable `car` des Datensatzes in einen Faktor (`as.factor`).
 - 2 Erstelle drei Box-Plots, in denen die von den Autotypen zurückgelegte Strecke visualisiert wird.

B3A Aufgabe lineare Regression II

- 3 Schätze für jeden Autotyp getrennt die Parameter des folgenden linearen Modell; nutze dafür die Funktion `lm()`

$$distance_i = \beta_0 + \beta_1 \cdot angle_i + \epsilon_i$$

- 4 Überprüfe die Anpassung des Modells indem Du die drei Regressionslinien in den Scatterplot einzeichnest (`distance` gegen `angle`). Spricht das

$$R^2$$

für eine gute Modellanpassung?

Einen schönen Output mit dem Paket stargazer

erzeugen

```
library(stargazer)
stargazer(m3, type="html")
```

Beispiel HTML Outputs:

	<i>Dependent variable:</i>
	mpg
wt	-3.125*** (0.911)
cyl	-1.510*** (0.422)
am	0.176 (1.304)
Constant	39.418*** (2.641)
Observations	32

Shiny App - Diagnostiken für die einfache lineare Regression

https://gallery.shinyapps.io/slr_diag/

Diagnostics for simple linear regression

Select a trend:

- ☐ Linear up
- ☐ Linear down
- ☐ Curved up
- ☐ Curved down
- ☒ Fan-shaped

☒ Show residuals

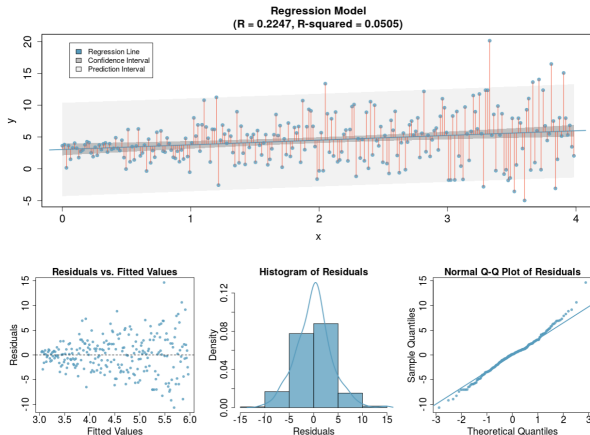
This applet uses ordinary least squares (OLS) to fit a regression line to the data with the selected trend. The applet is designed to help you practice evaluating whether or not the linear model is an appropriate fit to the data. The three diagnostic plots on the lower half of the page are provided to help you identify undesirable patterns in the residuals that may arise from non-linear trends in the data.

Rate this app!

[View code](#)

[Check out other apps](#)

[Want to learn more for free?](#)



Links - lineare Regression

- Regression - **r-bloggers**
- Das komplette Buch von **Faraway**- sehr intuitiv geschriebenes Buch
- Gute Einführung auf **Quick-R**
- **Multiple Regression**
- **15 Arten von Regressionen die man kennen sollte**
- **ggeffects** - Erzeuge saubere Datensätze mit marginellen Effekten für 'ggplot' aus Modell Outputs